Sequence Labeling dengan HMM

Part-of-Speech Tagging Bahasa Indonesia menggunakan Algoritma Viterbi

Oleh :
Eko Sutrisno (ekosutrisno@mail.ugm.ac.id) - 25/568610/PPA/07153

1. Deskripsi Preprocessing dan Pembagian Data

Sebelum proses pelatihan model dilakukan, dataset dianalisis untuk memahami karakteristik korpus serta mengidentifikasi potensi permasalahan yang dapat mempengaruhi kinerja model POS Tagging berbasis Hidden Markov Model (HMM) dan algoritma Viterbi. Analisis ini bertujuan untuk menentukan strategi preprocessing yang tepat agar data yang digunakan dalam proses pelatihan memiliki konsistensi dan kualitas yang baik.

Dataset yang digunakan terdiri dari 10.030 kalimat dengan total 256.622 token dan 18.288 kata unik. Rata-rata panjang kalimat adalah 25,59 token, dengan panjang kalimat minimum 2 token dan maksimum 82 token. Dataset ini menggunakan 24 jenis POS tag yang mewakili kategori gramatikal kata dalam bahasa Indonesia. Selain itu, ditemukan 8.420 kata singleton (46,04%), yaitu kata yang hanya muncul satu kali dalam korpus, serta 1.079 kata ambigu yang memiliki lebih dari satu POS tag. Kondisi ini menunjukkan bahwa korpus memiliki keragaman kosakata yang cukup tinggi dan berpotensi menimbulkan permasalahan Out-of-Vocabulary (OOV) pada tahap inferensi model.

Analisis terhadap bentuk penulisan kata menunjukkan bahwa sebagian besar token ditulis dalam bentuk lowercase (67,42%), diikuti oleh title case (15,09%), mixed case (14,49%), dan uppercase (3,01%). Variasi kapitalisasi ini tidak hanya bersifat ortografis tetapi juga memiliki nilai linguistik, terutama dalam membedakan nama diri (proper noun) dan kata umum. Analisis lebih lanjut menunjukkan adanya 1.972 kelompok kata dengan lebih dari satu varian kapitalisasi, dan 817 di antaranya memiliki distribusi POS tag yang berbeda antar variannya. Hal ini menunjukkan bahwa normalisasi huruf secara penuh (lowercasing) berpotensi menggabungkan kata yang memiliki fungsi sintaktis yang berbeda.

Berdasarkan hasil analisis (`lampiran/hasil_analisis_dataset.txt`), strategi preprocessing yang diterapkan pada penelitian ini dirancang secara selektif agar tetap mempertahankan informasi linguistik yang relevan. Pertama, seluruh POS tag dinormalisasi ke bentuk huruf kapital untuk menghilangkan inkonsistensi anotasi seperti `FW` dan `fw`. Kedua, lowercasing global tidak diterapkan karena kapitalisasi kata terbukti berkaitan dengan perbedaan distribusi POS tag. Ketiga, token multi-kata dipertahankan sesuai anotasi dataset dan tidak dilakukan tokenisasi ulang agar struktur label tidak berubah. Keempat, token khusus seperti angka, tanda hubung, dan tanda baca dipertahankan karena beberapa di antaranya memiliki informasi sintaktis yang penting bagi model.

Dalam tugas ini digunakan 80% data set atau sebesar 8.024 kalimat untuk data latih dan 20% atau sebesar 2006 kalimat untuk pengujian.

```
(.venv) (base) mastris@ai:~/viterbi$ python3 viterbi_pos.py Data_POS-Tag-ID.tsv
[INFO] Membaca dataset dari: Data_POS-Tag-ID.tsv
[INFO] Total kalimat dibaca: 10030
[INFO] Jumlah train sentences: 8024
[INFO] Jumlah test sentences : 2006
[INFO] Training HMM...
[INFO] Training selesai.
============================================================
INFO MODEL HMM
============================================================
Jumlah tag     : 23
Jumlah vocab   : 15879
Daftar tag     : CC, CD, DT, FW, IN, JJ, MD, NEG, NN, NND, NNP, OD, PR, PRP, RB, RP, SC, SYM, UH, VB, WH, X, Z
```

2. Strategi Penanganan Unkown Word

Strategi penanganan *unknown word* pada sistem POS Tagging ini dilakukan dengan beberapa langkah sederhana. Ketika sebuah kata diproses, sistem terlebih dahulu mencoba menggunakan probabilitas emisi dari bentuk kata yang sama persis dengan yang ada pada data pelatihan. Jika bentuk tersebut tidak ditemukan, tetapi bentuk huruf kecilnya pernah muncul, maka sistem menggunakan distribusi tag dari bentuk huruf kecil tersebut. Dengan cara ini, model masih dapat memanfaatkan informasi yang sudah dipelajari meskipun terdapat perbedaan penulisan seperti huruf kapital di awal kata.

Jika kata tersebut benar-benar tidak pernah muncul dalam data pelatihan, sistem menggunakan heuristic berbasis pola kata (suffix-based heuristic) untuk memperkirakan kemungkinan tag. Heuristik ini melihat ciri-ciri kata seperti tanda baca, angka, huruf kapital, serta pola awalan dan akhiran yang umum dalam bahasa Indonesia, misalnya akhiran *-kan*, *-i*, *-an* atau awalan *me-*, *ber-*, *di-*. Pendekatan ini dipilih karena bahasa Indonesia memiliki pola morfologi yang cukup jelas sehingga bentuk kata sering memberikan petunjuk terhadap kelas katanya, misalnya kata berakhiran *-kan* cenderung berupa verba atau kata berakhiran *-an* sering berupa nomina.

3. Tabel hasil evaluasi

```
(.venv) (base) mastris@ai:~/viterbi$ python3 viterbi_pos.py Data_POS-Tag-ID.tsv
[RESULT] Token-level Accuracy: 95.59%

[INFO] Menghitung metrik per-tag ...
+======+=======+==================================+============+============+============+============+
| No   | Tag   | Nama POS                         | Precision  | Recall     | F1         | Accuracy   |
+======+=======+==================================+============+============+============+============+
| 1    | CC    | Coordinating Conjunction         | 0.9901     | 0.9856     | 0.9879     | 0.9760     |
| 2    | CD    | Cardinal Number                  | 0.9885     | 0.9668     | 0.9776     | 0.9561     |
| 3    | DT    | Determiner                       | 1.0000     | 1.0000     | 1.0000     | 1.0000     |
| 4    | FW    | Foreign Word                     | 0.2667     | 0.3077     | 0.2857     | 0.1667     |
| 5    | IN    | Preposition / Subordinating      | 0.9609     | 0.9687     | 0.9648     | 0.9319     |
| 6    | JJ    | Adjective                        | 0.9160     | 0.9042     | 0.9101     | 0.8350     |
| 7    | MD    | Modal                            | 0.9459     | 0.9850     | 0.9651     | 0.9325     |
| 8    | NEG   | Negation                         | 1.0000     | 0.9833     | 0.9916     | 0.9833     |
| 9    | NN    | Noun                             | 0.9357     | 0.9509     | 0.9432     | 0.8925     |
| 10   | NND   | Derived Noun                     | 0.9845     | 0.9427     | 0.9631     | 0.9289     |
| 11   | NNP   | Proper Noun                      | 0.9337     | 0.9123     | 0.9229     | 0.8568     |
| 12   | OD    | Ordinal Number                   | 0.8273     | 0.7222     | 0.7712     | 0.6276     |
| 13   | PR    | Particle / Pronoun Marker        | 0.9925     | 0.9925     | 0.9925     | 0.9851     |
| 14   | PRP   | Personal Pronoun                 | 0.9932     | 0.9993     | 0.9962     | 0.9925     |
| 15   | RB    | Adverb                           | 0.9495     | 0.9709     | 0.9601     | 0.9232     |
| 16   | RP    | Particle                         | 0.7353     | 0.8929     | 0.8065     | 0.6757     |
| 17   | SC    | Subordinating Conjunction        | 0.9420     | 0.9604     | 0.9511     | 0.9067     |
| 18   | SYM   | Symbol                           | 0.1429     | 1.0000     | 0.2500     | 0.1429     |
| 19   | UH    | Interjection                     | 0.5000     | 0.6000     | 0.5455     | 0.3750     |
| 20   | VB    | Verb                             | 0.9796     | 0.9618     | 0.9706     | 0.9429     |
| 21   | WH    | Wh-Word                          | 0.9326     | 0.9432     | 0.9379     | 0.8830     |
| 22   | X     | Unknown / Other                  | 0.8000     | 0.1455     | 0.2462     | 0.1404     |
| 23   | Z     | Punctuation                      | 0.9814     | 0.9991     | 0.9902     | 0.9805     |
+======+=======+==================================+============+============+============+============+
```

Hasil tersebut menunjukkan bahwa model HMM + Viterbi yang digunakan sudah memiliki kinerja yang sangat baik secara umum, dengan token-level accuracy sebesar 95,59%. Ini berarti sebagian besar token pada data uji berhasil diberi tag dengan benar. Kinerja tinggi ini juga terlihat pada banyak tag utama seperti DT, PR, PRP, NEG, Z, CC, CD, VB, RB, SC, dan MD, yang memiliki nilai precision, recall, dan F1-score tinggi. Hal

ini menunjukkan bahwa model cukup mampu mempelajari pola transisi antar tag dan hubungan antara kata dengan kategori gramatikalnya, terutama untuk tag-tag yang frekuensinya relatif jelas dan konsisten dalam korpus. Tag seperti PRP (personal pronoun), Z (punctuation), dan DT (determiner) sangat mudah dikenali karena bentuk katanya relatif terbatas dan konteks kemunculannya cukup stabil.

4. Analisis

Kalimat nomer 1 : "*Ocalan adalah ketua Partai Pekerja Kurdistan (PKK) , yang melakukan pemberontakan bersenjata terhadap Ankara sejak 1984 .*"

Detail prediksi:

No	Word	Pred	Gold	Status	OOV	Catatan
1	Ocalan	NNP	NNP	BENAR	Known	title
2	adalah	VB	VB	BENAR	Known	-
3	ketua	NN	NN	BENAR	Known	ambigu
4	Partai	NNP	NNP	BENAR	Known	ambigu, title-mid
5	Pekerja	NNP	NNP	BENAR	Known	ambigu, title-mid
6	Kurdistan	NNP	NNP	BENAR	OOV total	OOV total, title-mid
7	(	Z	Z	BENAR	Known	-
8	PKK	NNP	NN	SALAH	OOV total	OOV total, upper
9	)	Z	Z	BENAR	Known	-
10	,	Z	Z	BENAR	Known	ambigu
11	yang	SC	SC	BENAR	Known	ambigu
12	melakukan	VB	VB	BENAR	Known	-
13	pemberontakan	NN	NN	BENAR	Known	-
14	bersenjata	VB	VB	BENAR	Known	ambigu
15	terhadap	IN	IN	BENAR	Known	-
16	Ankara	NNP	NNP	BENAR	OOV total	OOV total, title-mid
17	sejak	IN	IN	BENAR	Known	ambigu
18	1984	CD	CD	BENAR	Known	digit
19	.	Z	Z	BENAR	Known	ambigu

Akurasi kalimat ini: 18/19 = 94.74%

PKK merupakan OOV dan berpeluang memiliki makna, singkatan atau entitas yang berbeda.

Kalimat nomer 3: "*Para pengacara -nya di Roma hari Kamis mengklaim bahwa ia diracun di dalam penjara dan mereka mendesak PBB mengirim tim medis untuk melakukan penyelidikan .*"

Detail prediksi:

No	Word	Pred	Gold	Status	OOV	Catatan
1	Para	DT	DT	BENAR	Known	title
2	pengacara	NN	NN	BENAR	Known	-
3	-nya	PRP	PRP	BENAR	Known	ambigu, hyphen
4	di	IN	IN	BENAR	Known	ambigu
5	Roma	NN	NNP	SALAH	OOV total	OOV total, title-mid
6	hari	NN	NN	BENAR	Known	ambigu
7	Kamis	NNP	NNP	BENAR	Known	title-mid
8	mengklaim	VB	VB	BENAR	Known	-
9	bahwa	SC	SC	BENAR	Known	-
10	ia	PRP	PRP	BENAR	Known	-
11	diracun	VB	VB	BENAR	Known	-
12	di	IN	IN	BENAR	Known	ambigu
13	dalam	IN	NN	SALAH	Known	ambigu
14	penjara	NN	NN	BENAR	Known	-
15	dan	CC	CC	BENAR	Known	ambigu
16	mereka	PRP	PRP	BENAR	Known	-
17	mendesak	VB	VB	BENAR	Known	-
18	PBB	NNP	NNP	BENAR	Known	upper
19	mengirim	VB	VB	BENAR	Known	-
20	tim	NN	NN	BENAR	Known	ambigu
21	medis	JJ	JJ	BENAR	Known	-
22	untuk	SC	SC	BENAR	Known	ambigu
23	melakukan	VB	VB	BENAR	Known	-
24	penyelidikan	NN	NN	BENAR	Known	-
25	.	Z	Z	BENAR	Known	ambigu

Akurasi kalimat ini: 23/25 = 92.00%

Roma merupakan OOV dan title case di tengah kalimat, yang berpotensi rancu nama lokasi dan nama diri (NNP).

Kalimat nomer 13 : "*Baku tembak antara pria bersenjata dari Abkhazia dan polisi Georgia kadang kala terjadi di perbatasan de fakto tersebut dan korban jiwa tercatat setiap beberapa bulan .*"

Detail prediksi:

No	Word	Pred	Gold	Status	OOV	Catatan
1	Baku	NNP	RB	SALAH	OOV total	OOV total, title
2	tembak	VB	VB	BENAR	Known	-
3	antara	IN	IN	BENAR	Known	ambigu
4	pria	NN	NN	BENAR	Known	-
5	bersenjata	VB	VB	BENAR	Known	ambigu
6	dari	IN	IN	BENAR	Known	ambigu
7	Abkhazia	NNP	NNP	BENAR	OOV total	OOV total, title-mid
8	dan	CC	CC	BENAR	Known	ambigu
9	polisi	NN	NN	BENAR	Known	ambigu
10	Georgia	NNP	NNP	BENAR	Known	title-mid
11	kadang kala	NNP	RB	SALAH	OOV total	OOV total, multiword
12	terjadi	VB	VB	BENAR	Known	-
13	di	IN	IN	BENAR	Known	ambigu
14	perbatasan	NN	NN	BENAR	Known	-
15	de	NNP	X	SALAH	Known	-
16	fakto	NNP	X	SALAH	OOV total	OOV total
17	tersebut	PR	PR	BENAR	Known	-
18	dan	CC	CC	BENAR	Known	ambigu
19	korban	NN	NN	BENAR	Known	-
20	jiwa	NN	NN	BENAR	Known	ambigu
21	tercatat	VB	VB	BENAR	Known	-
22	setiap	CD	CD	BENAR	Known	-
23	beberapa	CD	CD	BENAR	Known	-
24	bulan	NN	NN	BENAR	Known	ambigu
25	.	Z	Z	BENAR	Known	ambigu

Baku merupakan OOV total dan berada di awal kalimat, sehingga model menebaknya sebagai NNP (nama diri) meskipun sebenarnya merupakan bagian dari frasa “baku tembak”.

“Kadang kala” merupakan token multiword yang OOV, sehingga heuristik model cenderung menganggapnya sebagai NNP, padahal secara fungsi linguistik merupakan RB.

5. Kesimpulan

Berdasarkan hasil evaluasi, model Hidden Markov Model (HMM) dengan algoritma Viterbi mampu melakukan proses Part-of-Speech Tagging Bahasa Indonesia dengan kinerja yang sangat baik. Model memperoleh token-level accuracy sebesar 95,59%, yang menunjukkan bahwa sebagian besar token pada data uji berhasil diberi label POS secara tepat. Hal ini menunjukkan bahwa pendekatan probabilistik yang memanfaatkan probabilitas emisi kata dan probabilitas transisi antar tag cukup efektif dalam memodelkan struktur sintaktis bahasa Indonesia.

Meskipun demikian, masih ditemukan beberapa keterbatasan pada model. Kesalahan prediksi terutama muncul pada kata yang tidak pernah muncul dalam data pelatihan (Out-of-Vocabulary/OOV), kata dengan variasi kapitalisasi yang ambigu, serta token multiword yang jarang muncul dalam korpus. Dalam kondisi tersebut, model cenderung mengandalkan probabilitas transisi antar tag sehingga prediksi yang dihasilkan terkadang kurang sesuai dengan fungsi linguistik kata tersebut.

Untuk meningkatkan kinerja sistem di masa mendatang, beberapa pengembangan dapat dilakukan, seperti memperbesar corpus pelatihan, menerapkan metode unknown word handling yang lebih adaptif, serta memanfaatkan fitur linguistik tambahan seperti morfologi kata atau pendekatan model yang lebih modern berbasis neural network. Dengan pengembangan tersebut, diharapkan sistem POS Tagging dapat memberikan hasil yang lebih akurat terutama pada kata baru dan struktur kalimat yang lebih kompleks.

6. Pernyataan Penggunaan AI

Dalam penyelesaian tugas ini, penulis menggunakan bantuan ChatGPT untuk memahami konsep, merancang alur program, mengimplementasikan sebagian kode program untuk mempercepat proses pemahaman, simulasi, eksplorasi serta penyelesaian tugas secara umum.